

自然语言处理研讨课 (实践课)

第8章 神经机器翻译实践

赵 阳

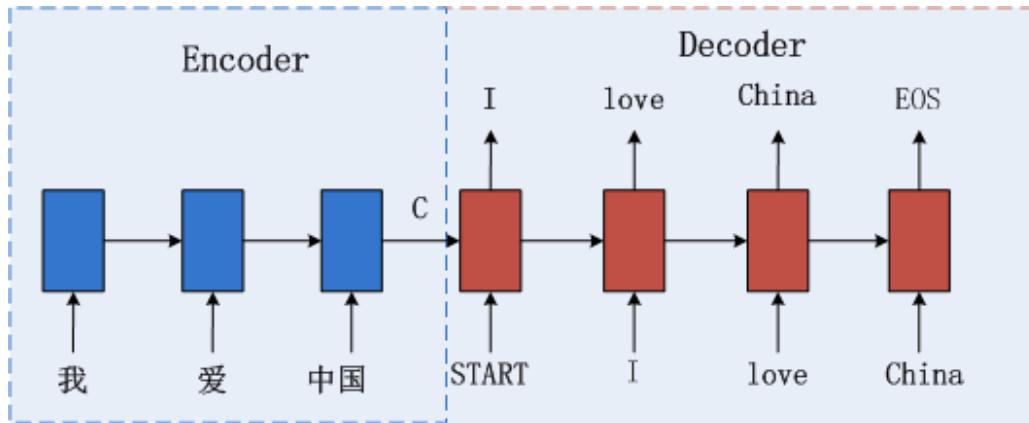
中国科学院自动化研究所
yang.zhao@nlpr.ia.ac.cn



本章内容

- ➔ 1. 神经机器翻译介绍
- 2. 实践基础
- 3. 实践参考
- 4. 本章实践

1. 神经机器翻译

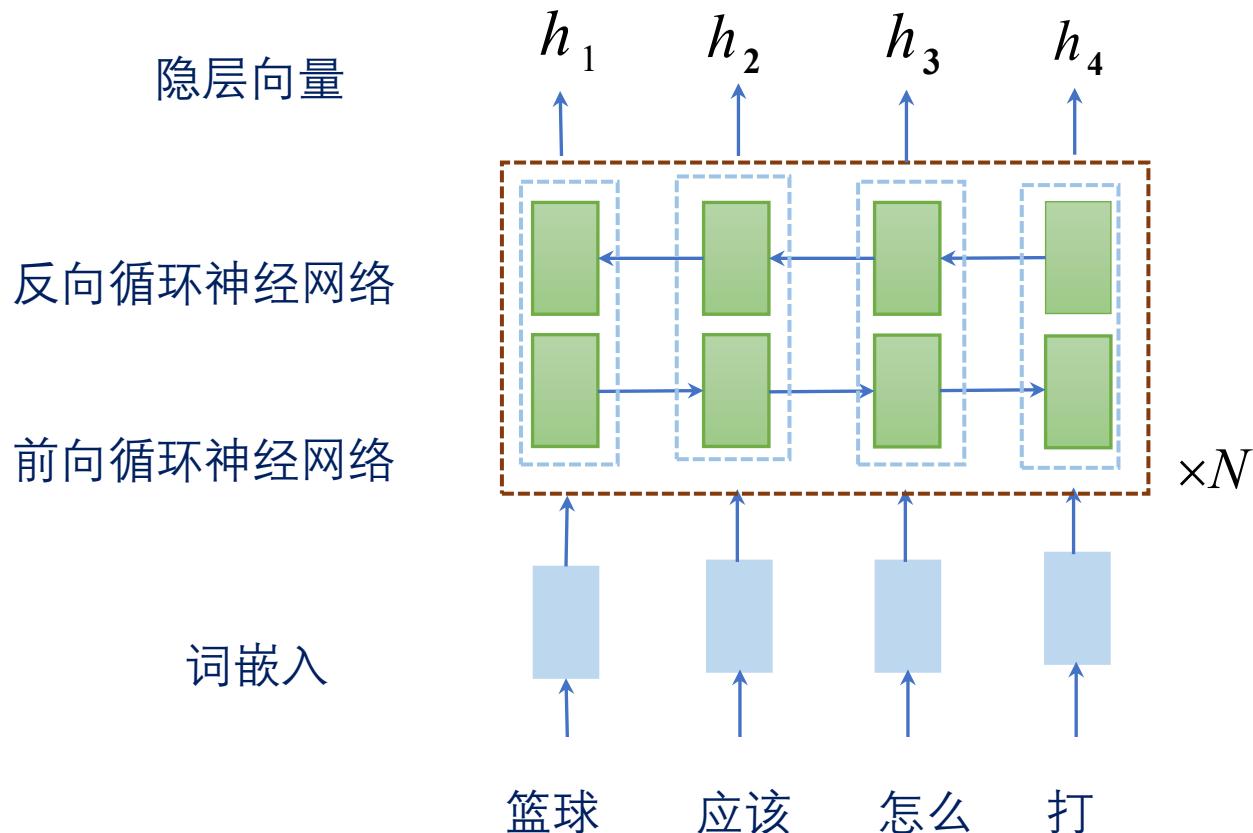


- 编码器 (Encoder)：
将源语言X编码成语义向量C
- 编码器 (Decoder):
根据语义向量C逐步生成目标语言Y

$$X \rightarrow C \rightarrow Y$$

1. 神经机器翻译

● 基于循环神经网络建模句子

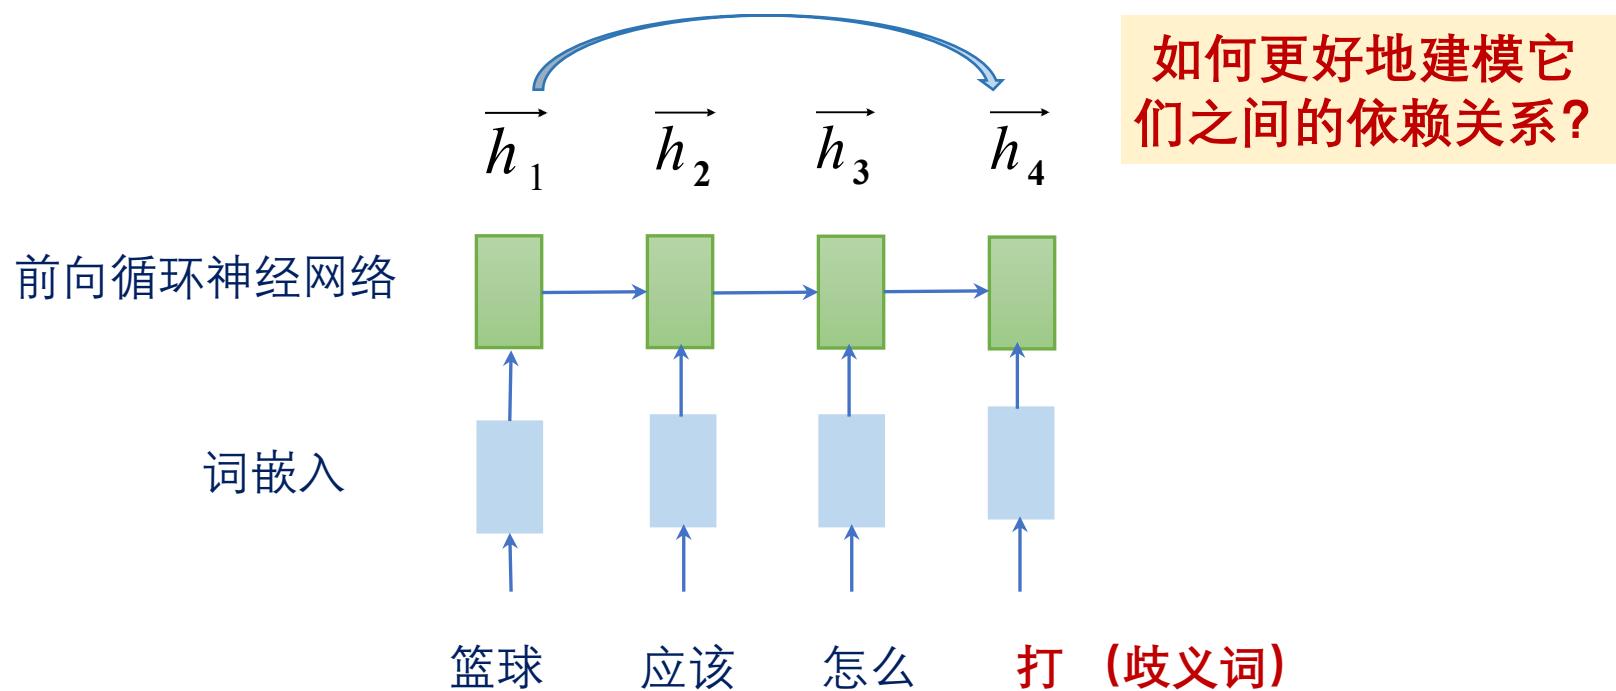


1. 神经机器翻译

● 基于循环神经网络实现句子建模的缺点

(1) 无法较好地处理长距离依赖问题

循环神经网络通过逐词建模的方式对句子进行建模，无法较好处理长距离单词之间的依赖关系。

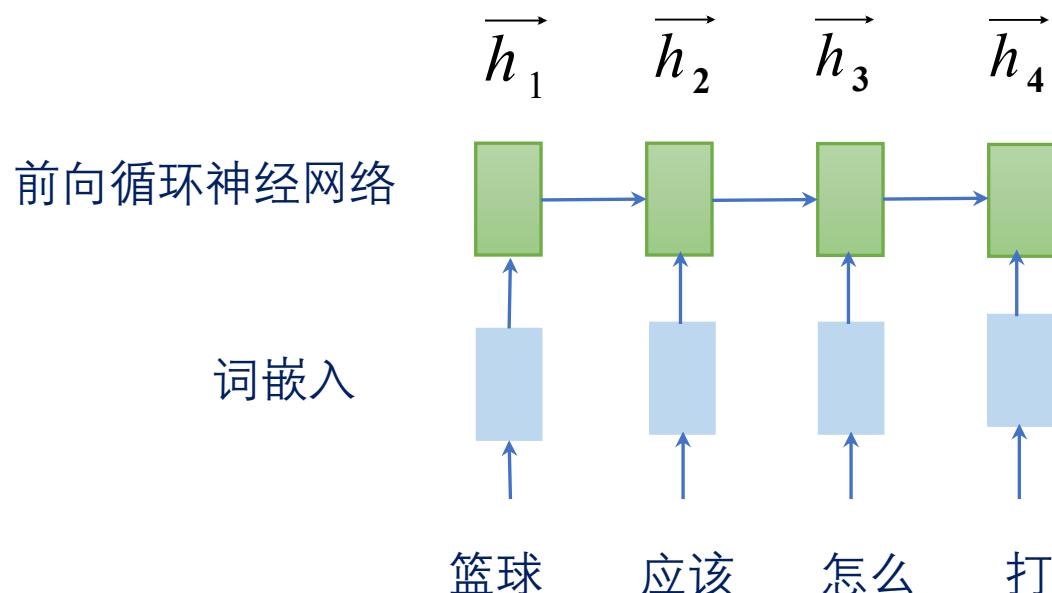


1. 神经机器翻译

● 基于循环神经网络实现句子建模的缺点

(2) 无法并行计算、计算效率较低

循环神经网络中，位置 i 的隐层状态的计算 \vec{h}_i ，需要依赖前一位置 $i-1$ 的隐层状态 \vec{h}_{i-1} 。





1. 神经机器翻译

● 基于自注意力机制 (Self-attention) 的神经网络-Transformer

1. 更好地建模单词之间的长距离依赖关系
2. 更好地实现并行计算，提升计算效率

◆ 代表论文：

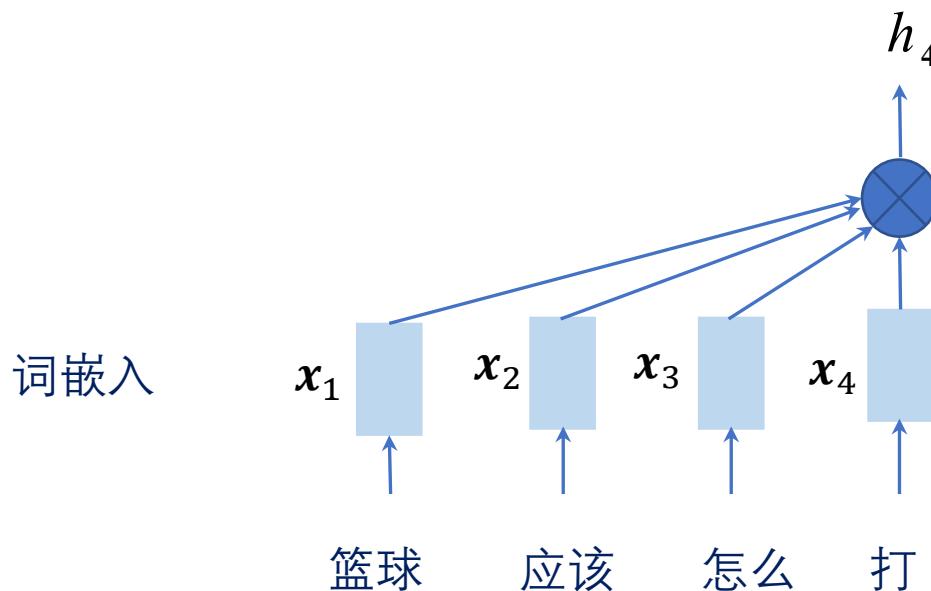
- A. Vaswani et al. [Attention Is All You Need](#). Advances in Neural Information Processing Systems 30 (NIPS 2017) December 4-7, 2017, Long Beach, CA, USA, Pages 6000–6010

1. 神经机器翻译

● 自注意力机制的优势：

(1) 能够较好地建模单词间的长距离依赖关系

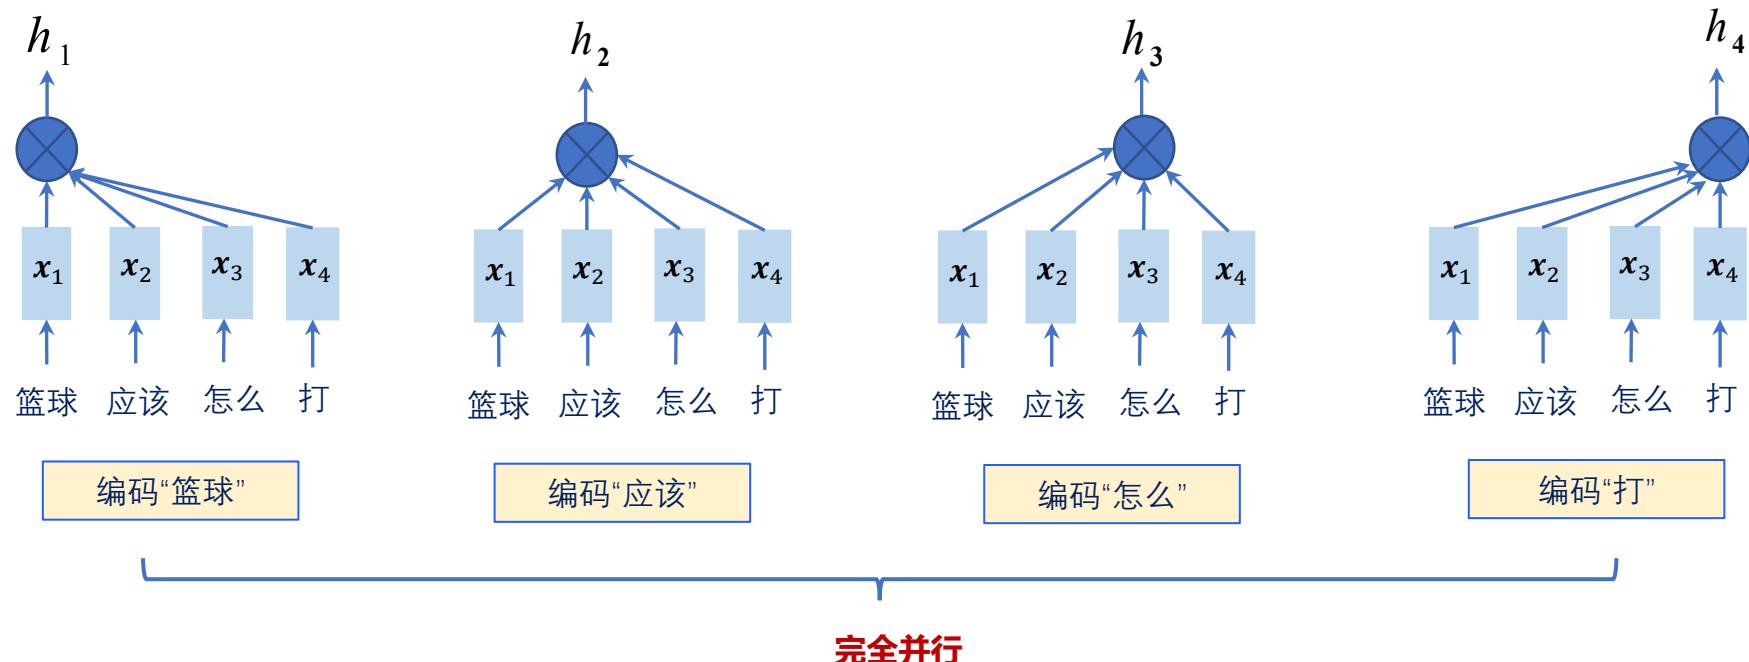
句子中任何两个单词之间通过自注意力机制，能够直接进行连接。



1. 神经机器翻译

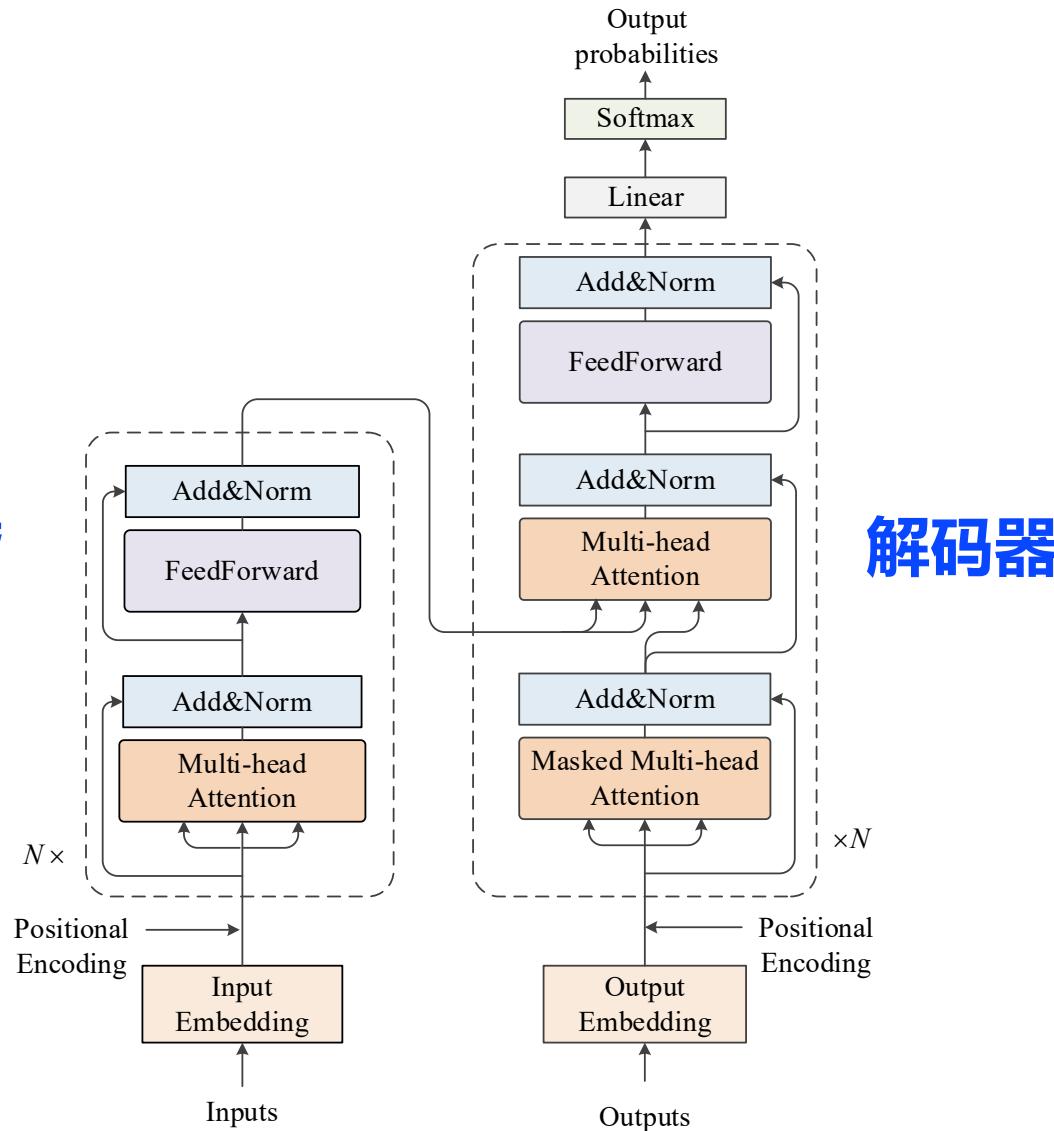
● 自注意力机制的优势：

(2) 能够实现并行计算，提升计算效率



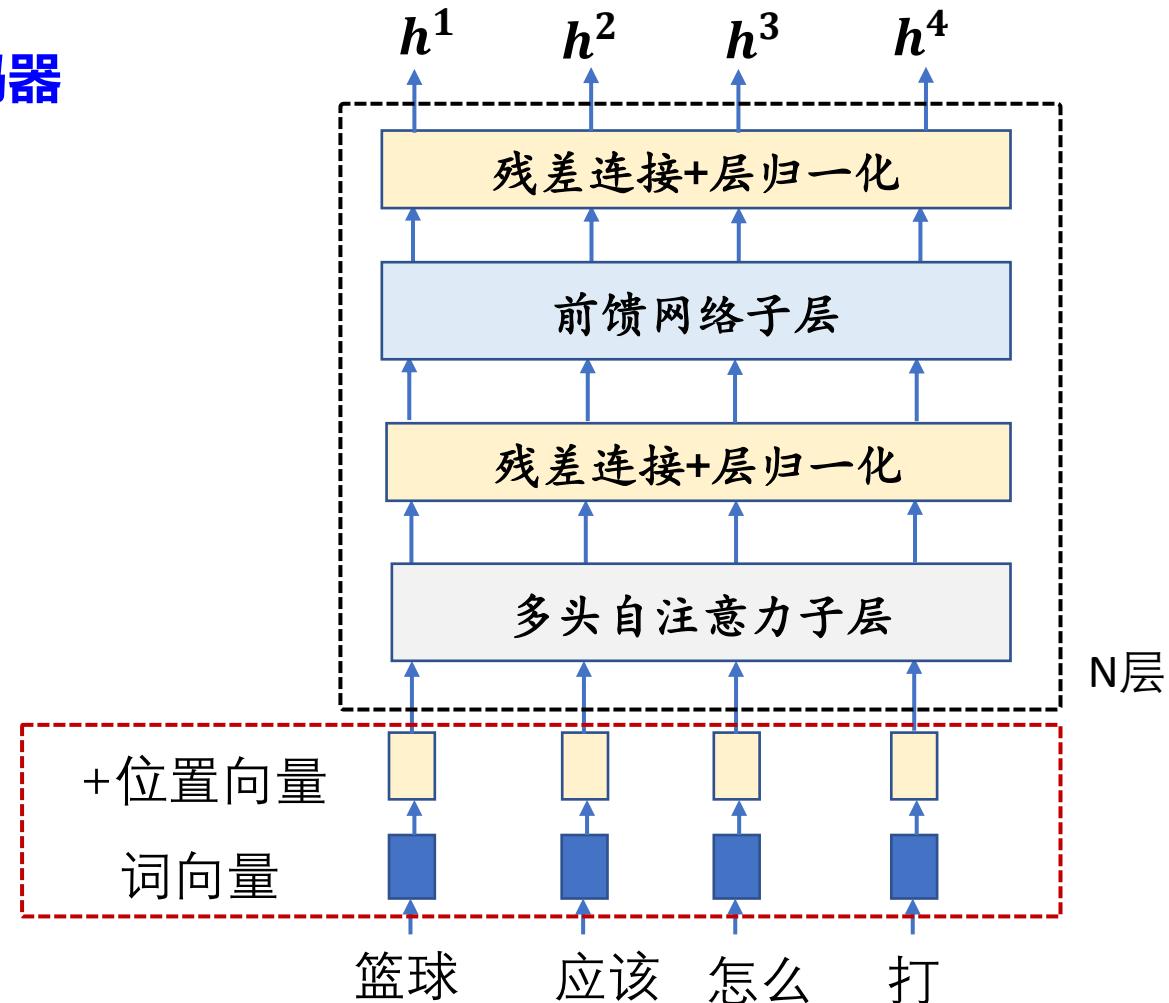
1. 神经机器翻译

编码器



1. 神经机器翻译

● Transformer编码器



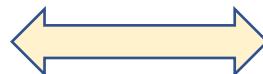
1. 神经机器翻译

● 为什么要增加位置向量？

- 句子中**单词的位置关系**对于句子语义有重要作用
- 自注意力机制不采用**循环结构**或者**卷积结构**，不包含位置信息

语义不等价

句子1：A队 打败了 B队



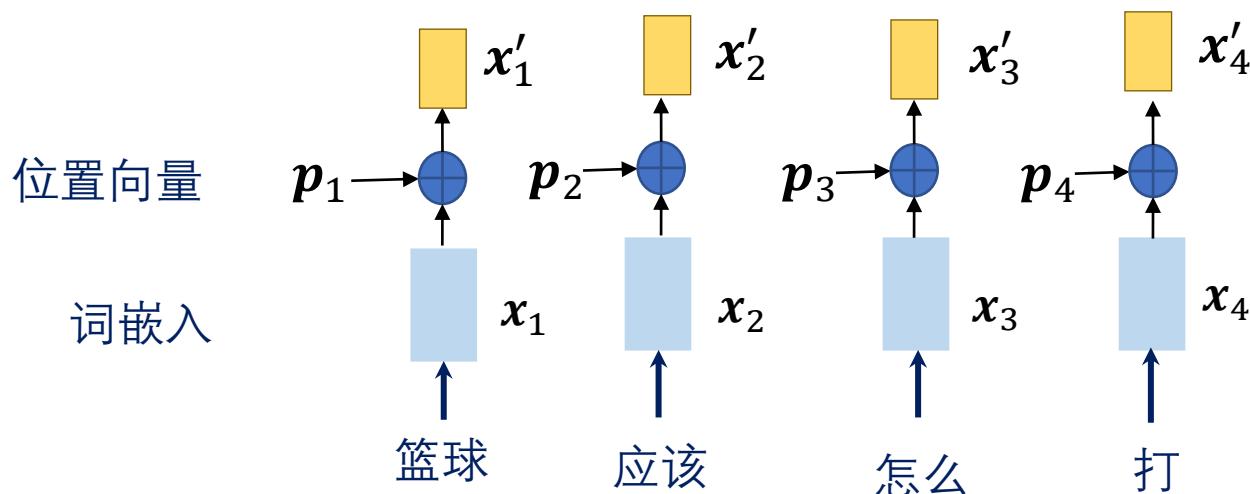
句子2：B队 打败了 A队

1. 神经机器翻译

● 增加位置向量

查询n个单词的词向量 (x_1, x_2, \dots, x_n) , 添对应的位置向量 (p_1, p_2, \dots, p_n)

$$(x'_1, x'_2, \dots, x'_n) = (x_1, x_2, \dots, x_n) + (p_1, p_2, \dots, p_n)$$





1. 神经机器翻译

● 向量位置如何确定？

- (1) 看作参数，随机初始化，根据训练数据进行优化；
- (2) 按照规则确定，并固定不变。

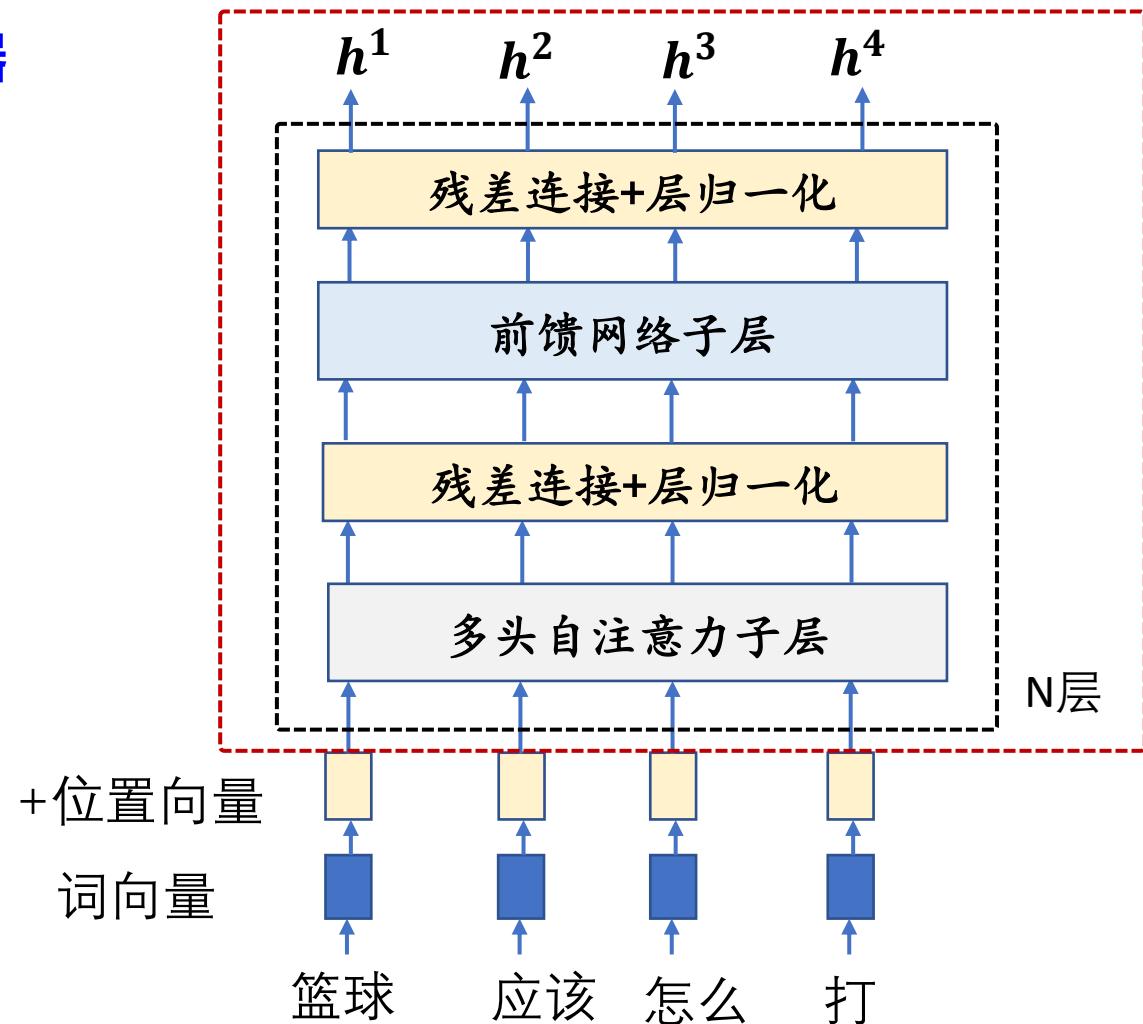
其中， pos 是位置， d 是总的维度数。 $2i$ 或 $2i+1$ 分别表示第 $2i$ 或者 $2i+1$ 维元素， $0 \leq i \leq d/2-1$ 。

$$p_{pos} = \begin{bmatrix} y_0 \\ \vdots \\ y_i \\ \vdots \\ y_{d-1} \end{bmatrix} \quad d \text{ (如: } d=500\text{)}$$

$$y_{2i} = \sin\left(\frac{pos}{10000^{(2i/d)}}\right)$$
$$y_{2i+1} = \cos\left(\frac{pos}{10000^{(2i/d)}}\right)$$

1. 神经机器翻译

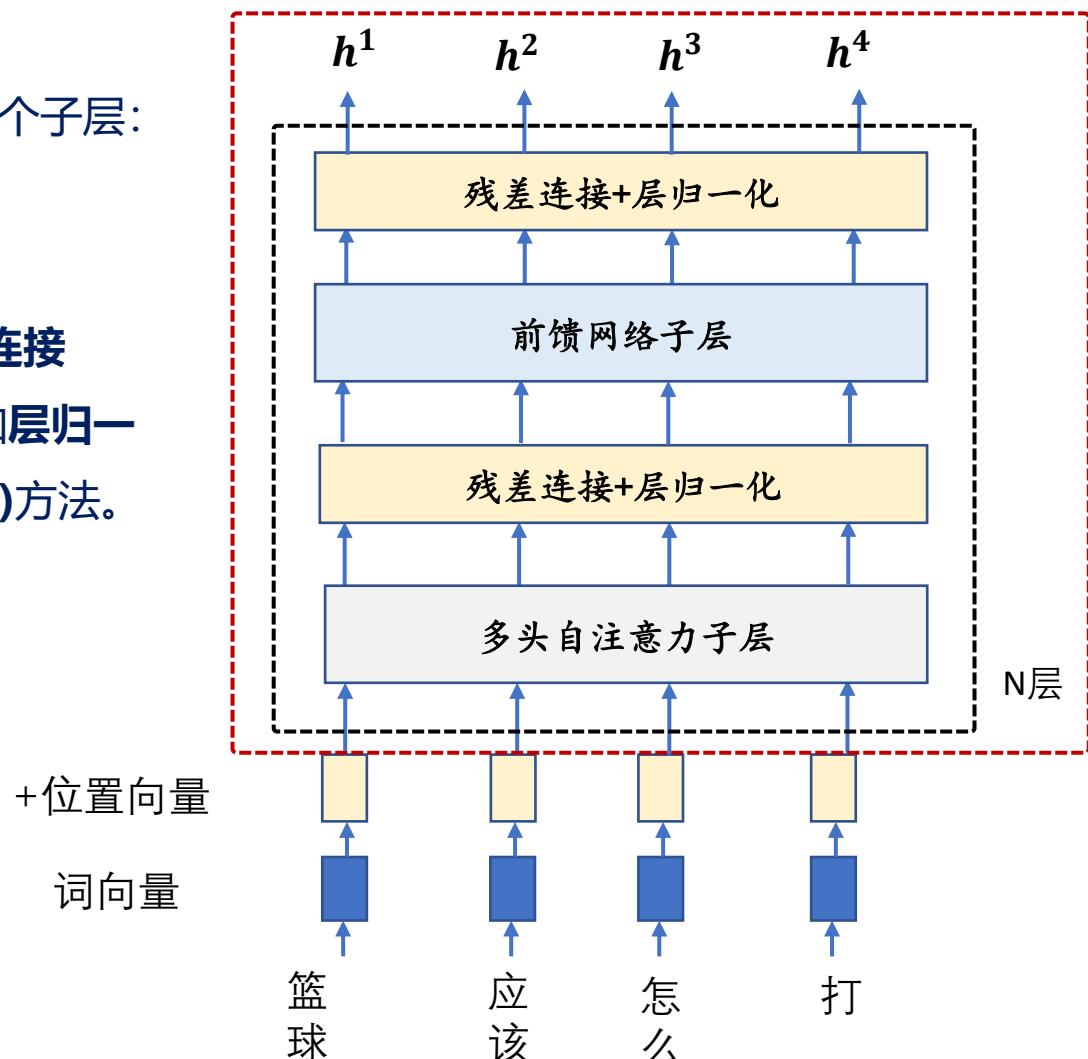
● Transformer编码器



1. 神经机器翻译

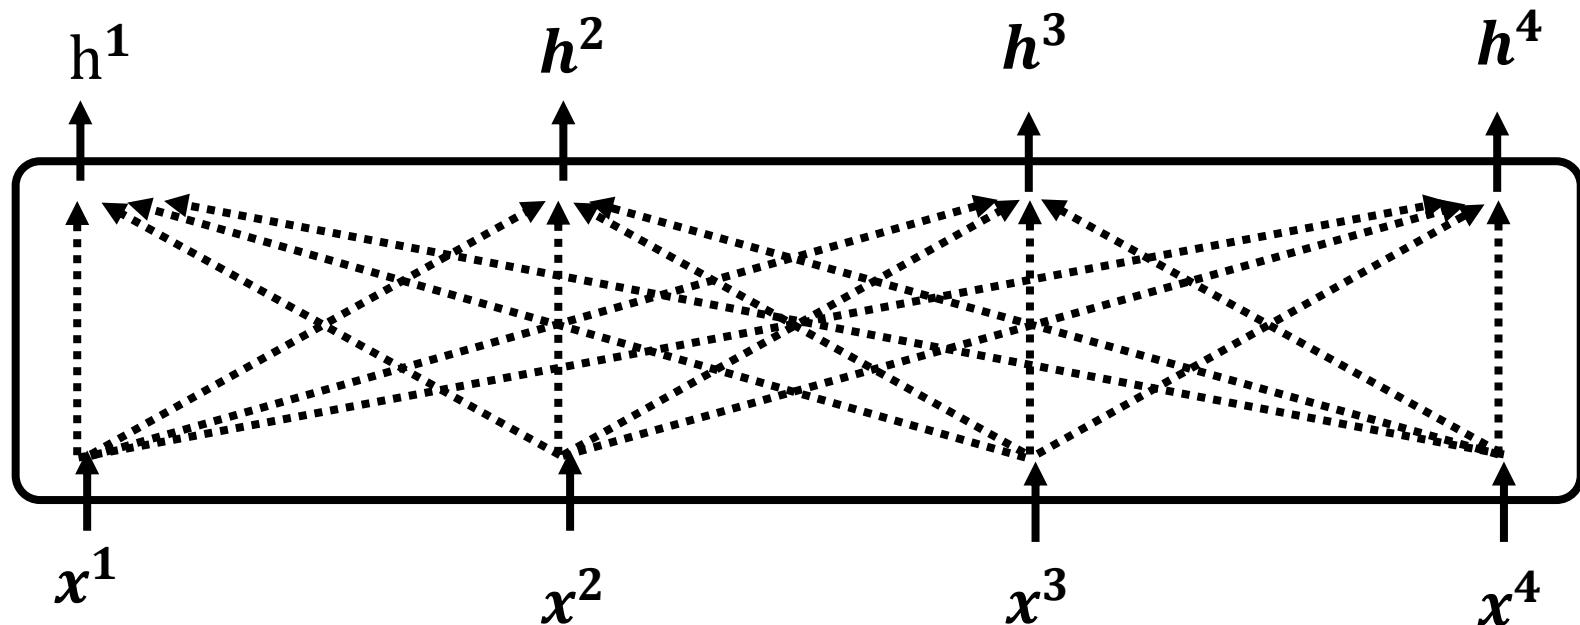
● Transformer编码器

- 由N层组成，每一层包括2个子层：
 - 多头自注意力子层
 - 前馈网络子层
- 每个子层之后采用了**残差连接**(residual connection)和**层归一化**(layer normalization)方法。



1. 神经机器翻译

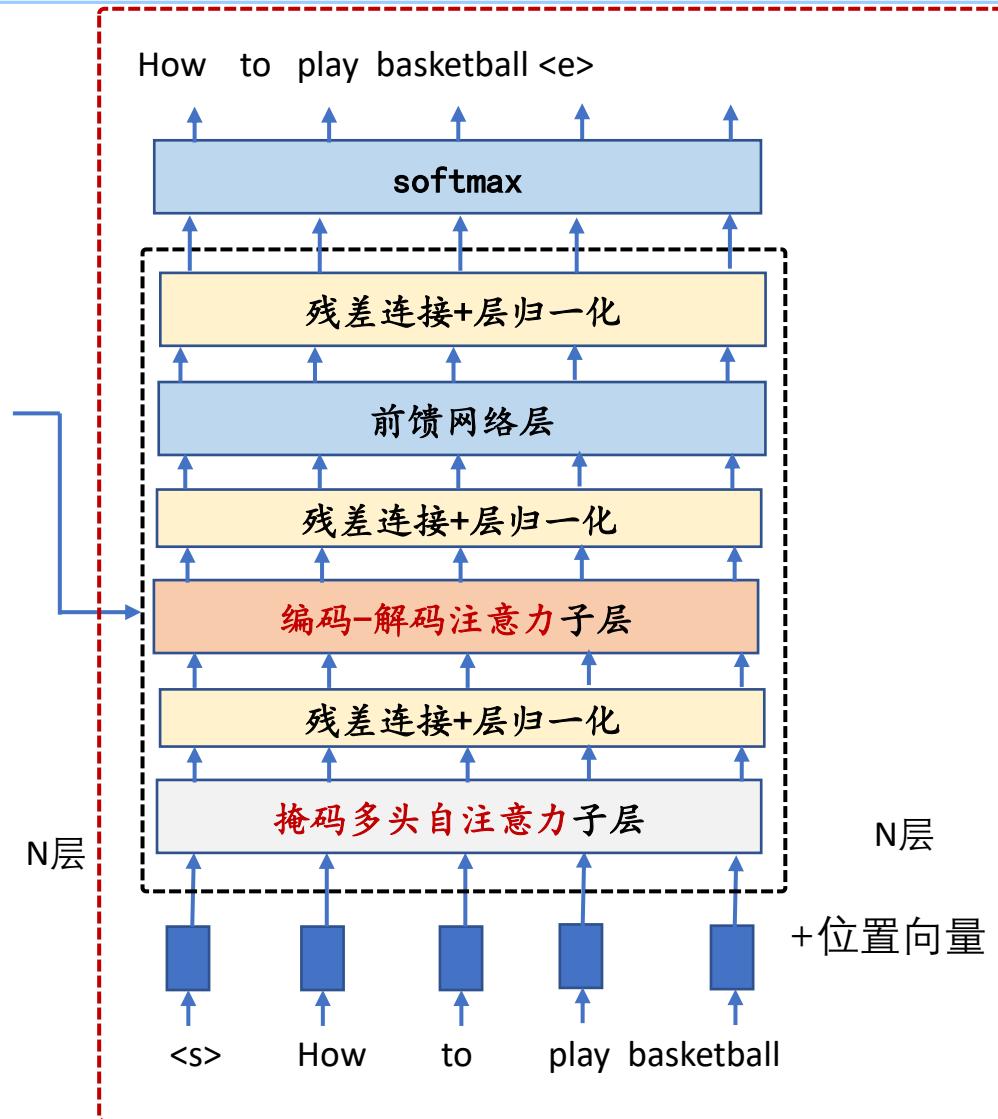
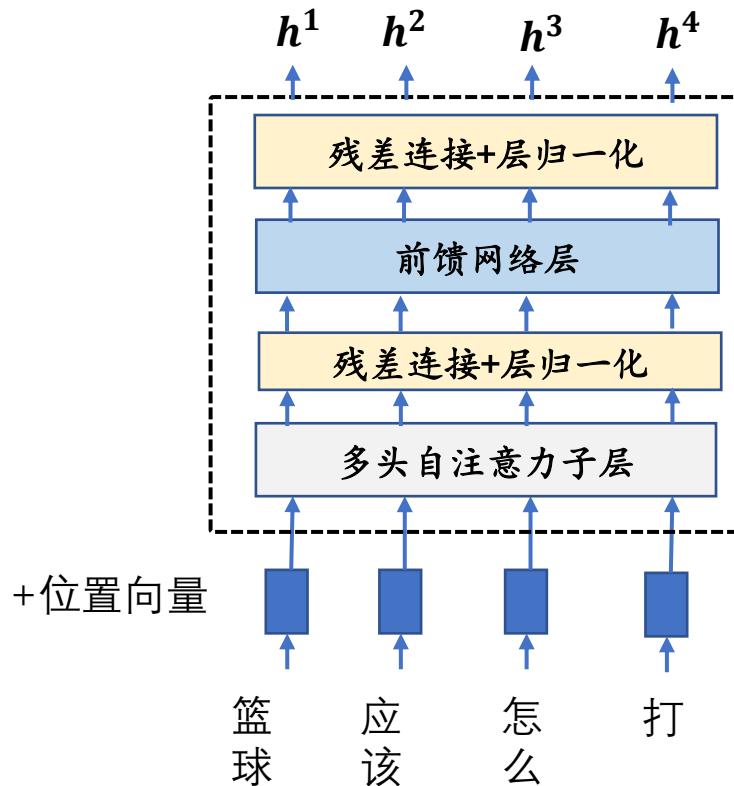
- 多头自注意力子层



编码器的自注意力机制示意图
(同时注意左右两端上下文)

1. 神经机器翻译

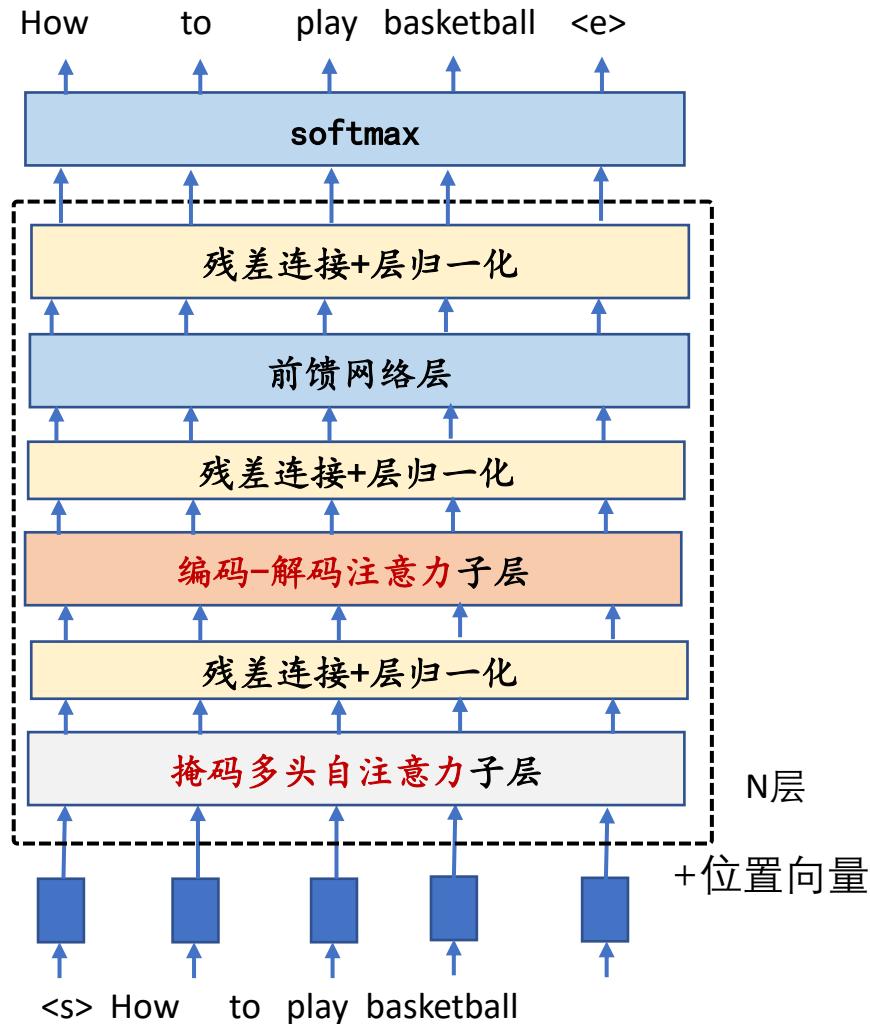
● Transformer解码器



1. 神经机器翻译

解码器

- 由N层组成，每一层包括3个子层：
 - 掩码多头自注意力子层；
 - 编码-解码注意力子层；
 - 前馈网络子层
- 每个子层之间采用了残差连接
(residual connection)和层归一化
(layer normalization)方法。



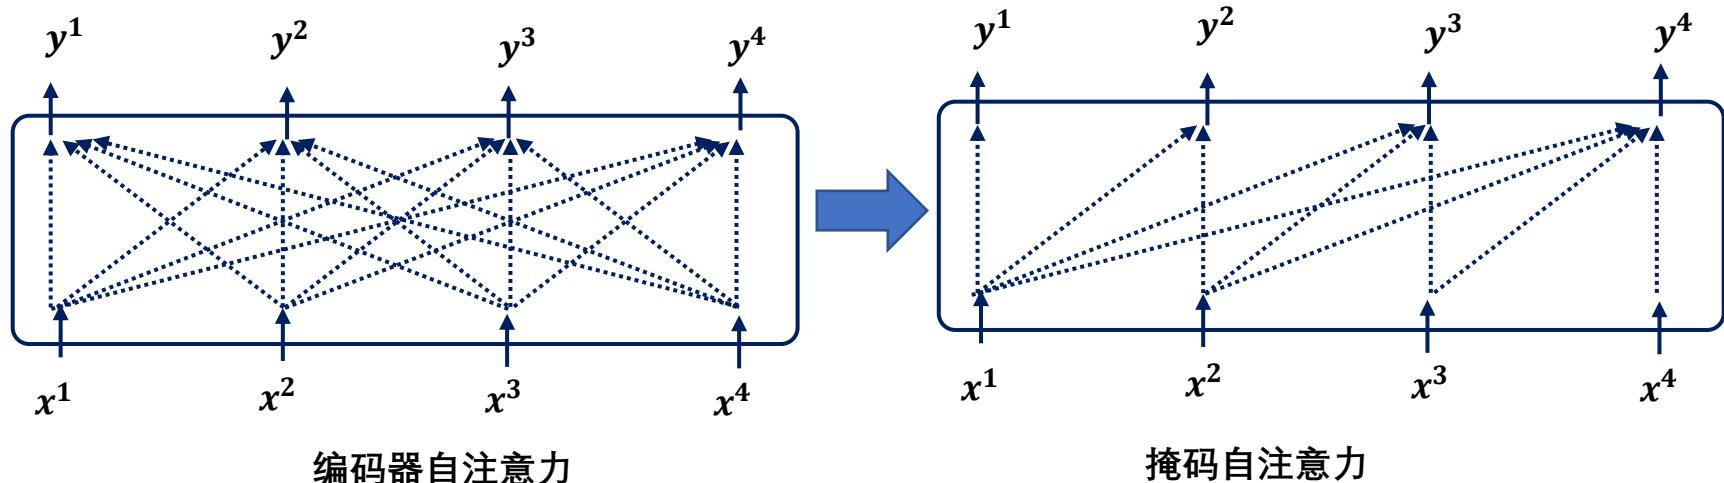
1. 神经机器翻译

掩码多头自注意力子层

- 在对于某一个目标端单词而言，只与之前单词做注意力计算，即把后面的单词掩盖。
- 为了保证模型在**训练阶段和测试阶段保持一致**，因此在测试阶段，需要将后续的单词掩盖。

训练阶段，标准译文是已知的；

测试阶段，模型仅已知之前的单词（模型自身预测得到）。





本章内容

1. 神经机器翻译介绍
2. 实践基础
3. 实践参考
4. 本章实践

2. 实践基础

■ 实践三个主要途径

- 本次实践采用PyTorch自带的Transformer

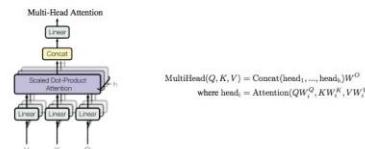
<https://pytorch.org/docs/stable/generated/torch.nn.Transformer.html#torch.nn.Transformer>

- Hugging Face的Transformers

https://github.com/huggingface/transformers/blob/main/i18n/README_zh-hans.md

- 不用自带的模型和库，可以阅读下面代码 (**强烈建议大家学习下**)：

<https://github.com/hyunwoongko/transformer>



$\text{MultiHead}(Q, K, V) = \text{Concat}(\text{head}_1, \dots, \text{head}_h)W^O$
where $\text{head}_i = \text{Attention}(QW_i^Q, KW_i^K, VW_i^V)$

```
class MultiHeadAttention(nn.Module):
    def __init__(self, d_model, n_head):
        super(MultiHeadAttention, self).__init__()
        self.n_head = n_head
        self.attention = ScaleDotProductAttention()
        self.w_q = nn.Linear(d_model, d_model)
        self.w_k = nn.Linear(d_model, d_model)
        self.w_v = nn.Linear(d_model, d_model)
        self.w_concat = nn.Linear(d_model, d_model)

    def forward(self, q, k, v, mask=None):
        # 1. dot product with weight matrices
        q, k, v = self.w_q(q), self.w_k(k), self.w_v(v)

        # 2. split tensor by number of heads
        q, k, v = self.split(q), self.split(k), self.split(v)

        # 3. do scale dot product to compute similarity
        out, attention = self.attention(q, k, v, mask=mask)

        # 4. concat and pass to linear layer
        out = self.concat(out)
        out = self.w_concat(out)
```



2. 实践基础

■ 机器翻译实践的数据

- 平行数据
(逐句对应)

英语句子

汉语句子

1 new Questions Over California Water Project
2 cri@ tics and a state law@ maker say they want more explan@ ations on who@
back@ ed by Go@ v@ . Jer@ ry Brow@ n, after a leading California water di-
government fun@ ding to fin@ ish the planning for the two gi@ ant water tur-
3 cri@ tics said the government fun@ ding described by the Los Angel@ es@ -k
could run coun@ ter to long-@ standing state ass@ ur@ ances that various]
pay for Brow@ n@ 's vision of di@ ging tw@ in 3@ 5-@ mil@ e-@ long ti-
River sou@ th, mainly for Central and Southern Californi@ a.
4 the \$@ 24@ 8 million in pre@ li@ min@ ary sp@ ending for the tun@ n@ e-
is the topic of an on@ going fed@ eral aud@ it.
5 on W@ ed@ nes@ day, state law@ makers ordered a state au@ dit of the tun@
6 on Th@ urs@ day, state spo@ k@ es@ woman N@ ancy V@ og@ el said that c-
ropol@ itan Water District, no money from the state@ 's general fun@ d woul-
tw@ in tun@ n@ els.

1 加利福尼亚州的水务工程的新问题
2 在加利福尼亚州一个主要水务管理区披露州政府资金以完成两条巨型输水隧道的表示，他们想进一步了解由谁来为州长承担费用。
3 评论家表示，洛杉矶的MCE WCE DCE周所提来的承诺，该承诺说，为了实现布朗所以来便于把水从萨克拉门托河向南输送地区的愿景，各地方水务管区（而非加利福尼亚州）将负责这两条隧道的2.48亿美元初期费用支出。进行的联邦审计的主题。
4 一些州议员也于周一责令对隧道费用该州的发言人在南希·沃格尔周一四表示，却不会动用该州的任何普通资金来完成这



2. 实践基础

- 位置编码（自定义层）

$$y_{2i} = \sin\left(\frac{pos}{10000^{(2i/d)}}\right) \quad y_{2i+1} = \cos\left(\frac{pos}{10000^{(2i/d)}}\right)$$

继承nn.Module

初始化

[max_len, 1] 的
张量

[max_len, 1,
d_model] 的张量
和赋值

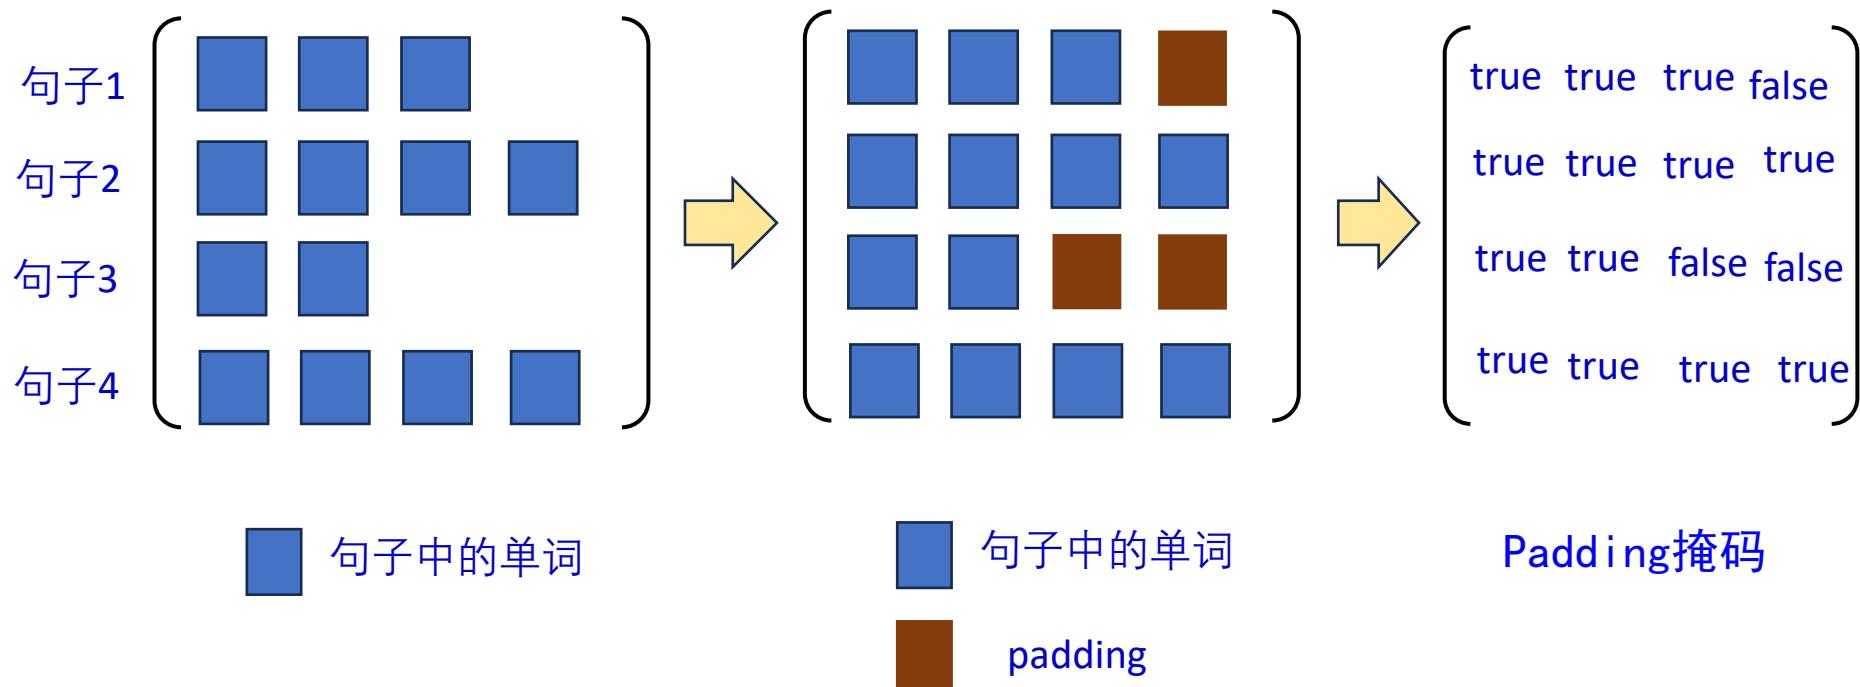
自定义前向计算

```
class PositionalEncoding(nn.Module):  
  
    def __init__(self, d_model: int, dropout: float = 0.1, max_len: int = 5000):  
        super().__init__()  
        self.dropout = nn.Dropout(p=dropout)  
        position = torch.arange(max_len).unsqueeze(1)  
        div_term = torch.exp(torch.arange(0, d_model, 2) * (-math.log(10000.0) / d_model))  
        pe = torch.zeros(max_len, 1, d_model)  
        pe[:, 0::2] = torch.sin(position * div_term)  
        pe[:, 1::2] = torch.cos(position * div_term)  
        self.register_buffer('pe', pe)  
  
    def forward(self, x):  
        """  
        Arguments:  
        x: Tensor, shape ``[seq_len, batch_size, embedding_dim]``  
        """  
        x = x + self.pe[:x.size(0)]  
        return self.dropout(x)
```

2. 实践基础

■ 批处理的Padding掩码

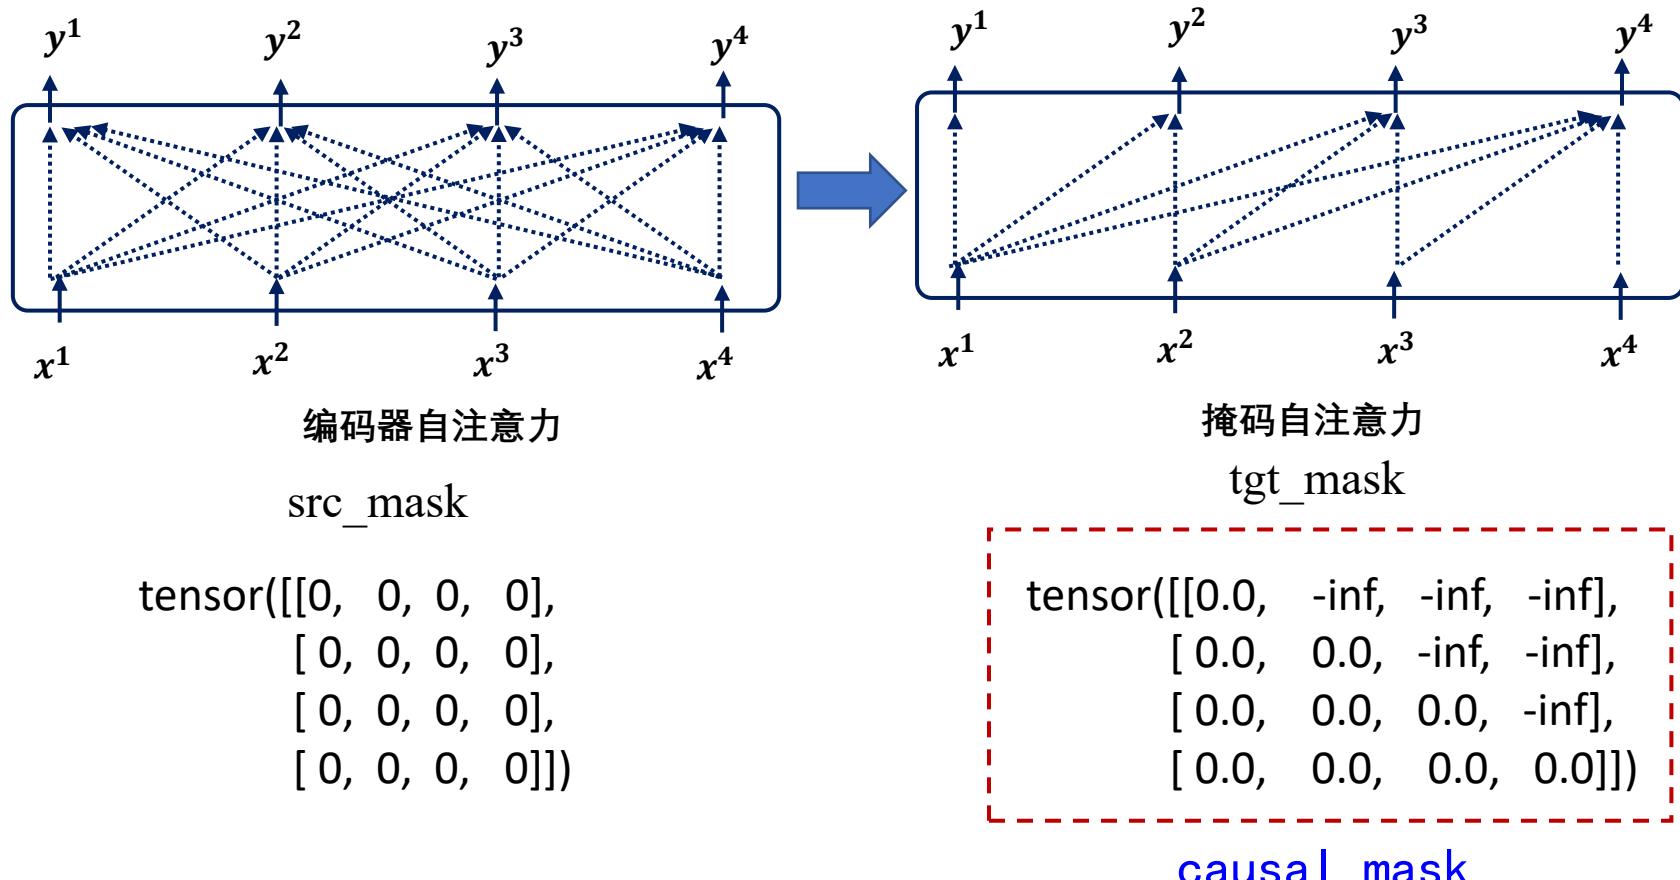
- 同一批次里，句子长度不同，需要额外增加padding；
- Padding掩码能够指示对应位置是否是padding。



2. Transformer语言模型实践

■ 因果掩码

- 因果掩码能够指示模型是否能够注意未来信息。





2. Transformer语言模型实践

- PyTorch集成的Transformer

```
forward(src, tgt, src_mask=None, tgt_mask=None, memory_mask=None, src_key_padding_
mask=None, tgt_key_padding_mask=None, memory_key_padding_mask=None, src_is_cau
sal=None, tgt_is_causal=None, memory_is_causal=False)
```

Parameters

- **src** (*Tensor*) – the sequence to the encoder (required).
- **tgt** (*Tensor*) – the sequence to the decoder (required).
- **src_mask** (*Optional[Tensor]*) – the additive mask for the src sequence (optional).
- **tgt_mask** (*Optional[Tensor]*) – the additive mask for the tgt sequence (optional).
- **memory_mask** (*Optional[Tensor]*) – the additive mask for the encoder output (optional).
- **src_key_padding_mask** (*Optional[Tensor]*) – the Tensor mask for src keys per batch (optional).
- **tgt_key_padding_mask** (*Optional[Tensor]*) – the Tensor mask for tgt keys per batch (optional).
- **memory_key_padding_mask** (*Optional[Tensor]*) – the Tensor mask for memory keys per batch (optional).

因果掩码

Padding掩码



2. Transformer语言模型实践

- PyTorch新的版本

无需额外构建因果矩阵

```
output = model(src, tgt, src_mask=None, tgt_mask= None, src_key_padding_mask=src_mask,  
tgt_key_padding_mask=tgt_mask, src_is_causal=False, tgt_is_causal=True)
```

只需设置是否因果即可



本章内容

1. 神经机器翻译介绍
2. 实践基础
3. 实践参考
4. 本章实践





3. 实践参考

■ 导入的库

```
import math
import torch
from torch import nn
from torch.nn import Transformer
from torch.utils.data import Dataset, DataLoader
import json
import argparse
from collections import namedtuple
```



3. 实践参考

■ Main函数 (1/3)

```
if __name__ == '__main__':
    parser = argparse.ArgumentParser()
    parser.add_argument("--src_file", type=str, default="./cleaned_translation/train.en")
    parser.add_argument("--tgt_file", type=str, default="./cleaned_translation/train.zh")
    parser.add_argument("--src_eval_file", type=str, default="./cleaned_translation/val.en")
    parser.add_argument("--tgt_eval_file", type=str, default="./cleaned_translation/val.zh")
    parser.add_argument("--src_vocab_file", type=str,
                       default="./cleaned_translation/train.en.json")
    parser.add_argument("--tgt_vocab_file", type=str,
                       default="./cleaned_translation/train.zh.json")
    parser.add_argument("--batch_size", type=int, default=16)
    parser.add_argument("--epochs", type=int, default=10)
    parser.add_argument("--lr", type=float, default=1e-4)
    parser.add_argument("--check_interval", type=int, default=100)
    parser.add_argument("--device", type=str, default="cpu")
    parser.add_argument("--max_len", type=int, default=300)
    parser.add_argument('--d_model', type=int, default=512)
    parser.add_argument('--nhead', type=int, default=8)
    parser.add_argument('--num_encoder_layers', type=int, default=6)
    parser.add_argument('--num_decoder_layers', type=int, default=6)
    parser.add_argument('--dim_feedforward', type=int, default=512)
    parser.add_argument('--dropout', type=float, default=0.1)
```

解析超参数

层数和维度不需要设置太多





3. 实践参考

■ Main函数 (2/3)

首先构建
Config 字典
然后转为具名
元组

实例化模型

Dataset和
dataloader
数据批处理

模型训练

```
args = parser.parse_args()
config = {
    "src_vocab_size": len(json.load(open(args.src_vocab_file, "r", encoding="utf-8"))),
    "tgt_vocab_size": len(json.load(open(args.tgt_vocab_file, "r", encoding="utf-8"))),
    "max_len": args.max_len,
    "d_model": args.d_model,
    "nhead": args.nhead,
    "num_encoder_layers": args.num_encoder_layers,
    "num_decoder_layers": args.num_decoder_layers,
    "dim_feedforward": args.dim_feedforward,
    "dropout": args.dropout,
}
config = namedtuple("Config", config.keys())(*config.values())
model = TransformerModel(config)
model.to(args.device)
train_dataset = TranslateDataset(args.src_file, args.tgt_file, args.src_vocab_file,
                                 args.tgt_vocab_file)
train_dataloader = DataLoader(train_dataset, batch_size=args.batch_size,
                             shuffle=True, collate_fn=collate_fn)
eval_dataset = TranslateDataset(args.src_eval_file, args.tgt_eval_file,
                                args.src_vocab_file, args.tgt_vocab_file)
eval_dataloader = DataLoader(eval_dataset, batch_size=args.batch_size,
                            shuffle=False, collate_fn=collate_fn)
train(model, train_dataloader, args, eval_dataloader)
```



3. 实践参考

■ Main函数 (3/3)

在开发集上解
码翻译结果

```
eval_dataloader = DataLoader(eval_dataset, batch_size=1,
shuffle=False, collate_fn=collate_fn)
model.load_state_dict(torch.load("model_best.pth"))
model.eval()
text2id = json.load(open(args.tgt_vocab_file, "r"))
id2text = {v: k for k, v in text2id.items()}

for step, batch in enumerate(eval_dataloader):
    src, src_mask, tgt, tgt_mask, causal_mask = batch
    src = src.to(args.device)
    src_mask = src_mask.to(args.device)
    tgt = tgt.to(args.device)
    tgt_mask = tgt_mask.to(args.device)
    causal_mask = causal_mask.to(args.device)
    output = greedy_generate(model, src, src_mask, args, 0)
    output = output.squeeze(0).tolist()
    output = [id2text[x] for x in output]
    output = " ".join(output)
    print(output)
```

自己完成



3. 实践参考

■ 位置向量类

位置向量
参考之前的内容

{

```
class PositionalEncoding(nn.Module):
```

$$y_{2i} = \sin\left(\frac{pos}{10000^{(2i/d)}}\right)$$

$$y_{2i+1} = \cos\left(\frac{pos}{10000^{(2i/d)}}\right)$$



3. 实践参考

■ TransformerModel类 (1/2)

Transformer
层的定义

```
class TransformerModel(nn.Module):
    def __init__(self, config):
        super().__init__()
        self.srcEmbedding = nn.Embedding(config.src_vocab_size, config.d_model)
        self.tgtEmbedding = nn.Embedding(config.tgt_vocab_size, config.d_model)
        self.PositionalEncoding = PositionalEncoding(config.d_model, config.dropout,
                                                     config.max_len)
        self.model = Transformer(config.d_model, config.nhead,
                               config.num_encoder_layers, config.num_decoder_layers, config.dim_feedforward,
                               config.dropout, batch_first=True)
        self.fc = nn.Linear(config.d_model, config.tgt_vocab_size)
```



3. 实践参考

■ TransformerModel类 (2/2)

Transformer
前向传播

```
def forward(self, src, tgt, src_mask=None, tgt_mask=None,
           src_key_padding_mask=None, tgt_key_padding_mask=None,
           src_is_causal=False, tgt_is_causal=False):
    src = self.srcEmbedding(src)
    src = self.PositionalEncoding(src)
    tgt = self.tgtEmbedding(tgt)
    tgt = self.PositionalEncoding(tgt)
    out = self.model(src=src, tgt=tgt, src_mask=src_mask, tgt_mask=tgt_mask,
                     src_key_padding_mask=src_key_padding_mask,tgt_key_padding_mask=tgt_ke
                     y_padding_mask, memory_key_padding_mask=src_key_padding_mask)
    out = self.fc(out)
    return out
```



3. 实践参考

■ 字典类

加载字典

句子前后增加开始和结束字符

```
class Tokenizer:  
    def __init__(self, vocab):  
        self.vocab = json.load(open(vocab, "r", encoding="utf-8"))  
        # eos 0, bos 1, unk 2, pad 3  
  
    def encode(self, text):  
        chrs = text.strip().split(' ')  
        ids = [self.vocab.get(chr, 2) for chr in chrs]  
        if ids[0] != 1:  
            ids = [1] + ids  
        if ids[-1] != 0:  
            ids = ids + [0]  
        return ids
```



3. 实践参考

■ TranslateDataset

```
class TranslateDataset(Dataset):
    def __init__(self, src_file, tgt_file, src_tokenizer, tgt_tokenizer):
        self.src_file = src_file
        self.tgt_file = tgt_file
        self.src_tokenizer = Tokenizer(src_tokenizer)
        self.tgt_tokenizer = Tokenizer(tgt_tokenizer)
        self.src_texts = []
        self.tgt_texts = []
        self._load_data()

    def _load_data(self):
        with open(self.src_file, "r", encoding="utf-8") as f:
            self.src_texts = f.readlines()
        with open(self.tgt_file, "r", encoding="utf-8") as f:
            self.tgt_texts = f.readlines()
        assert len(self.src_texts) == len(self.tgt_texts)

    def __len__(self):
        return len(self.src_texts)

    def __getitem__(self, idx):
        src_text = self.src_texts[idx]
        tgt_text = self.tgt_texts[idx]
        src_ids = self.src_tokenizer.encode(src_text)
        tgt_ids = self.tgt_tokenizer.encode(tgt_text)
        return src_ids, tgt_ids
```

处理源语言和目标语言的数据，
构建TranslateDataset



3. 实践参考

■ collate_fn

```
def collate_fn(data):
    src_input = [item[0] for item in data]
    tgt_input = [item[1] for item in data]
    batch_size = len(src_input)
    src_seq_len = max([len(item) for item in src_input])
    tgt_seq_len = max([len(item) for item in tgt_input])
    src_mask = torch.ones((batch_size, src_seq_len)).long()
    tgt_mask = torch.ones((batch_size, tgt_seq_len)).long()
    src = torch.ones((batch_size, src_seq_len)).long().fill_(3)
    tgt = torch.ones((batch_size, tgt_seq_len)).long().fill_(3)
    for i in range(batch_size):
        src[i, :len(src_input[i])] = torch.tensor(src_input[i])
        tgt[i, :len(tgt_input[i])] = torch.tensor(tgt_input[i])
    src_mask = (src == 3)
    tgt_mask = (tgt == 3)
    causal_mask = make_causal_mask(tgt_mask)
    return src, src_mask, tgt, tgt_mask, causal_mask
```

与之前章节的内容相似，

- pytorch旧版本需要构建因果掩码和padding掩码
- Pytorch新版本只需padding掩码

```
def make_causal_mask(attention_mask):
    """
    0 for unmasked, -inf for masked
    """
    bsz, seq_len = attention_mask.shape
    mask = torch.ones((seq_len, seq_len)).tril()
    return mask
```



3. 实践参考

■ 模型训练 (1/2)

```
def train(model, dataloader, args, eval_dataloader):
    optimizer = torch.optim.Adam(model.parameters(), lr=args.lr)
    criterion = nn.CrossEntropyLoss()
    lowest_loss = 1e12
    for epoch in range(args.epochs):
        for step, batch in enumerate(dataloader):
            src, src_mask, tgt, tgt_mask, causal_mask = batch
            src = src.to(args.device)
            src_mask = src_mask.to(args.device)
            tgt = tgt.to(args.device)
            tgt_mask = tgt_mask.to(args.device)
            causal_mask = causal_mask.to(args.device)
            output = model(src, tgt, src_mask=None, tgt_mask=causal_mask,
                           src_key_padding_mask=src_mask, tgt_key_padding_mask=tgt_mask,
                           src_is_causal=False, tgt_is_causal=True)
            output = output[:, :-1, :]
            output = output.reshape(-1, output.shape[-1])
            tgt = tgt[:, 1:]
            tgt = tgt.reshape(-1)
            loss = criterion(output, tgt)
            optimizer.zero_grad()
            loss.backward()
            optimizer.step()
```

将因果掩码和padding掩码
传给模型



3. 实践参考

■ 模型训练 (2/2)

验证模型性能

```
if step % args.check_interval == 0:  
    print("Epoch: {}, Step: {}, Loss: {}".format(epoch, step, loss.item()))  
    eval_loss = eval(model, eval_dataloader, args)  
    if eval_loss < lowest_loss:  
        lowest_loss = eval_loss  
        torch.save(model.state_dict(), "model_best.pth")  
return
```

自己实现



3. 实践参考

■ 模型验证

经过check_interval步，需要验证模型效果，计算loss，自己实现，难点从output->loss

```
def eval(model, dataloader, args):
    criterion = nn.CrossEntropyLoss(reduction='none')
    total_loss = 0
    total_num = 0
    model.eval()
    with torch.no_grad():
        for step, batch in enumerate(dataloader):
            ...
            print("Loss: {}".format(total_loss / total_num))
        model.train()
    return total_loss / total_num
```



3. 实践参考

■ 贪婪解码

- 解码阶段，采用贪婪解码，每次选择概率最大的字符，直到得到句子结束标签

选择概率最大的单词，
自己实现

解码得到句子结束标签

```
def greedy_generate(model, src, src_mask, args, eos_id):
    model.eval()
    ...
    if pred == eos_id:
        break
    return tgt
```



本章内容

1. 神经机器翻译介绍
2. 实践基础
3. 实践参考
4. 本章实践





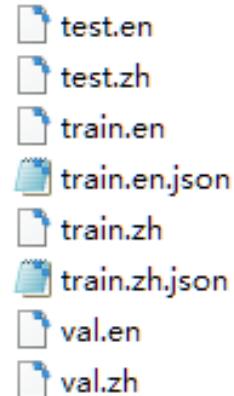
本章实践

■ 机器翻译实践

- 利用提供的翻译数据集，实现基于Transformer机器翻译方法。
- 在提供的数据集上训练实现的模型，并汇报最终的性能指标。
- 可以尝试新的方法和语言对。

不同语言对、不同机器翻译方法等

- 鼓励大家去阅读不依赖第三方库独立实现的Transformer方法，
便于理解Transformer原理





本章实践

■ 基本要求：

- 序列标注模型（第6章）、语言模型（第7章）和编码解码生成模型（第8章） 至少完成一项，鼓励大模型完成更多任务，完成任务越多分数越高。
- 报告需要说明使用的模型结构和方法、超参数、实验结果等；
- 不需要把程序大段复制上去，如果有需要，只需要截取和复制关键程序即可。
- 满足了基本要求就可以得到B（80-85分），剩余的15分取决于拓展分析和实验等。
- 提交时间（12月9日）。
- 提交地址课程网站。



谢谢！

Thanks!